

0.1 Estimation

0.2 Chaîne de Markov cachée

0.3 Méthode séquentielle - Approche Probabiliste

0.4 Filtrage bayésien

Le filtrage bayésien consiste à écrire la récurrence sur les lois de probabilité, pour estimer, en fonction des observations passées et courante $y_{1:k}$ l'état courant x_k et de prédire l'état future x_{k+1} .

Pour simplifier les notations, l'exposant $|^k$ qui conditionne la densité par les observations $y_{1:N}$. La densité de l'état est initialisée par la densité a priori de l'état initial p_{X_0} .

Puis pour tout $k \geq 0$ les lois de probabilité sont propagées.

L'étape de propagation ou *forecast* loi *a priori* est obtenue grace à la loi des probabilité totales

$$p_{X_{k+1}}^{|^k}(x) = \int p_{X_{k+1}|X_k=x'}(x) p_{X_k}^{|^k}(x') dx' \quad (1)$$

La loi *a priori* de la $k+1$ observations peut être obtenue de nouveau grace à la loi de probabilité totale

$$p_{Y_{k+1}}^{|^k}(y) = \int p_{Y_{k+1}|X_{k+1}=x}(y) p_{X_{k+1}}^{|^k}(x) dx$$

Après la $k+1$ observation y_{k+1} , l'étape d'*analyse* permet de déterminer la loi *a posteriori* de l'état avec la loi de Bayes appliquées après mesure de Y_n

$$p_{X_{k+1}}^{|^k+1}(x) = p_{X_{k+1}|Y_{k+1}=y_{k+1}}^{|^k}(x) = \frac{p_{Y_{k+1}|X_{k+1}=x}(y) p_{X_{k+1}}^{|^k}(x)}{p_{Y_{k+1}}^{|^k}(y)}.$$

la loi de Bayes après mesure de Y_n

0.4.1 Filtre de Kalman

Le filtre de Kalman introduit en 1960 [?] est une version du filtre Bayésien appliqué à un modèle linéaire Gaussien. Dans ces conditions, la distribution de l'état a priori de l'état et des observations sont défini par leur deux premiers moment tel que la propagation devient

$$E[X_{k+1}^{\{}} | midk] = ME[X_{k+1}^{\{}} | midk],$$

$$E[X_{k+1}^{\{}} | midk] = ME[X_{k+1}^{\{}} | midk] M^T + Q,$$

et le modèle d'observation donne

$$E[Y_{k+1}^{\{}} | midk] = ME[X_{k+1}^{\{}} | midk], E[X_{k+1}^{\{}} | midk] = ME[X_{k+1}^{\{}} | midk] M^T + R, [Y^{\{}} | midk, X^{\{}} | midk] = E[X_{k+1}^{\{}} | midk] H^T$$

De telle sorte que la distribution conditionnelle de Y_{k+1} par $|^k$ et X_{k+1} si cette dernière est non-dégénérée

$$E[Y^{\{}} | midk | X^{\{}} | midk] = ME[X_{k+1}^{\{}} | midk] +$$

$$E[Y_{k+1}^{\{ \}} | midk] = H$$

0.4.2 Filtre Particulaire

Le filtre particulaire est une implémentation du filtre bayésien qui approxime la PDF à l'aide d'une distribution empirique. Les transformations du filtre, *forecast* et *analysis* sont appliquées sur les membres de cet échantillon. Cette méthode converge vers la distribution exacte lorsque le nombre de particule $N \rightarrow \infty$.

Le prior de l'état $p(\mathbf{x})$ à l'instant k est représenté par un ensemble de N réalisations $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$ de tel sorte que

$$p_{\mathbf{X}_k}(\mathbf{x}) \simeq \sum_{i=1}^N \omega_k^i \delta(\mathbf{x} - \mathbf{x}_k^i) \quad \text{with} \quad \sum_{i=1}^N \omega_k^i = 1, \quad \omega_k^i > 0.$$

où δ est la masse de Dirac et ω_k^i les poids associés à chaque membre. Initialement, les échantillons sont supposés tirés de manière uniforme de tel sorte que $\omega_k^i = 1/N$.

Lors de l'étape de *propagation*, les particules sont propagées par le modèle de manière déterministe.

Pour s'en convaincre, le loi de probabilité totale ?? peut être réécrite

$$\begin{aligned} p_{\mathbf{X}_{k+1}}^{(k)}(\mathbf{x}) &= \int p_{\mathbf{X}_{k+1}|\mathbf{X}_k=\mathbf{x}'}(\mathbf{x}) p_{\mathbf{X}_k}^{(k)}(\mathbf{x}') d\mathbf{x}' \\ &\simeq \int p_{\mathbf{X}_{k+1}|\mathbf{X}_k=\mathbf{x}'}(\mathbf{x}) \sum_{i=1}^N \omega_k^i \delta(\mathbf{x}' - \mathbf{x}_k^i) d\mathbf{x}' \\ &\simeq \sum_{i=1}^N \omega_k^i \int p_{\mathbf{X}_{k+1}|\mathbf{X}_k=\mathbf{x}'}(\mathbf{x}) \delta(\mathbf{x}' - \mathbf{x}_k^i) d\mathbf{x}' \\ &\simeq \sum_{i=1}^N \omega_k^i \delta(\mathbf{x} - \mathcal{M}_{k,k+1}(\mathbf{x}_k^i) - \boldsymbol{\eta}_{k,k+1}) = \sum_{i=1}^N \omega_k^i \delta(\mathbf{x} - \mathbf{x}_{k+1}^i). \end{aligned}$$

Quant à l'étape d'analyse, elle correspond à une mise à jour du poids de chaque membre, qui correspond à sa vraisemblance conditionnée aux données

$$\begin{aligned} p_{\mathbf{X}_{k+1}}^{(k+1)}(\mathbf{x}) &\propto p_{\mathbf{Y}_{k+1}|\mathbf{X}_{k+1}=\mathbf{x}}^{(k)}(\mathbf{y}) \sum_{i=1}^N \omega_k^i \delta(\mathbf{x} - \mathbf{x}_{k+1}^i) \\ &\propto \sum_{i=1}^N \omega_k^i p_{\mathbf{Y}_{k+1}|\mathbf{X}_{k+1}=\mathbf{x}_{k+1}^i}^{(k)}(\mathbf{y}) \delta(\mathbf{x} - \mathbf{x}_{k+1}^i) \end{aligned}$$

Leading to

$$\omega_{k+1}^i = \frac{\omega_k^i p_{\mathbf{Y}_{k+1}|\mathbf{X}_{k+1}=\mathbf{x}_{k+1}^i}^{(k)}(\mathbf{y}_{k+1})}{\omega_k^j \sum_{j=1}^N p_{\mathbf{Y}_{k+1}|\mathbf{X}_{k+1}=\mathbf{x}_{k+1}^j}^{(k)}(\mathbf{y}_{k+1})}$$

Où le dénominateur est simplement un terme de normalisation.

Cependant, lorsque la dimension est grande, le nombre de poids non nulle a tendance à tendre vers 0. Pour éviter cela, des méthodes de rééchantillonnage du *posterior* ont été développées. Le filtre bootstrap [?] consiste à sélectionner les membres de poids les plus élevés, de les cloner de manière proportionnelle à leurs poids. Après échantillonnage, N particules sont rassemblées, dont certaines sont identiques avec des approximatifs égaux. Un exemple d'algorithme suivant

Algorithme 1 : Implémentation du rééchantillonnage par *bootstrap*.

```
1 pour membre  $n$  do faire
2   Tirer  $u$  dans  $\mathcal{U}[0, 1[$ ;
3   Initialiser  $j = 1$ ;
4   Affecter  $S_w = w^1$ ;
5   tant que  $S_w < u$  faire
6      $j = j + 1$ ;
7      $S_w = S_w + w(j)$ 
8   Le membre  $j$  est conservé et remplace le membre  $n$ .
```
